

# llm 里的二次筛选补充

Junle LI

May 2026

## 1 Sink-suppressed Residual Attention Selection

在第二阶段，本文借鉴 FastV 的剪枝位置设置，在 LLM 浅层输出后利用 attention 矩阵进一步筛选视觉 token。不同于直接依据视觉 token 接收的平均 attention score 进行排序，本文认为 raw attention 可能受到 attention sink 或 anchor token 的影响：部分视觉 token 可能被大量文本 query 普遍关注，但这并不意味着其与当前文本语义具有特异相关性。因此，本文构造 sink-suppressed residual attention 作为任务相关候选信号。

设第  $l$  层注意力矩阵为  $A^{(l)} \in R^{H \times L \times L}$ ，首先对多头注意力取平均：

$$\bar{A}^{(l)} = \frac{1}{H} \sum_{h=1}^H A_h^{(l)}.$$

视觉 token 区间记为  $\mathcal{V} = [s_v, e_v]$ 。为了避免显式区分 system prompt 与 user instruction，本文直接选取所有位于视觉 token 之后、且非视觉的 query token 作为文本查询集合：

$$\mathcal{Q} = \{q \mid q \notin \mathcal{V}, q \geq e_v\}.$$

随后取 text-to-vision attention 子矩阵：

$$A_{q,i}^{tv} = \bar{A}_{q,i}^{(l)}, \quad q \in \mathcal{Q}, i \in \mathcal{V}.$$

为了消除不同 query token 在视觉区域上的 attention mass 差异，先对每个 query 在视觉 token 维度上归一化：

$$P_{q,i} = \frac{A_{q,i}^{tv}}{\sum_{j \in \mathcal{V}} A_{q,j}^{tv} + \epsilon}.$$

为了抑制被所有文本 query 普遍关注的 attention sink, 本文估计每个 visual token 的 query-independent attention bias:

$$b_i = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} P_{q,i}.$$

随后构造残差 attention:

$$R_{q,i} = [P_{q,i} - b_i]_+.$$

若某个 visual token 被所有文本 query 普遍关注, 则其  $P_{q,i}$  与  $b_i$  接近, 残差值较低; 而如果该 token 仅被部分文本 query 特异关注, 则会获得更高残差响应。基于此, visual token 的残差相关性定义为:

$$c_i = \frac{1}{m} \sum_{q \in \text{Topm}(R_{:,i})} R_{q,i}.$$

给定第一阶段已选择集合  $S_1$ , 第二阶段首先从剩余视觉 token 中根据  $c_i$  构造候选池:

$$\mathcal{P}_2 = \text{TopM}_{i \in \mathcal{V} \setminus S_1}(c_i), \quad M_2 = \eta K_2.$$

最终选择仍由多样性主导。设第  $l$  层视觉 token 表示为  $z_i = H_i^{(l)}$ , 定义余弦距离:

$$D(i, j) = 1 - \cos(z_i, z_j).$$

在第  $t$  次迭代中, 选择与当前已保留集合最不冗余的候选:

$$s_t = \arg \max_{i \in \mathcal{P}_2 \setminus S_2} \min_{j \in S_1 \cup S_2^{(t)}} D(i, j), \quad t = 1, \dots, K_2.$$

最终保留集合为

$$S = S_1 \cup S_2.$$

该策略并不直接依赖 raw attention, 而是先去除 query-independent attention sink bias, 再利用残差 attention 构造候选池, 最后通过多样性选择补充第一阶段尚未覆盖的视觉信息。