

视觉部分筛选

Junle LI

May 2026

1 Coverage-aware Candidate Selection

为了避免简单响应强度筛选可能偏向高范数背景 token, 本文采用 coverage-aware 的候选选择策略。该策略受到 DivPrune 的启发, 其核心思想是通过最大化候选 token 之间的最小距离, 优先构建能够覆盖不同视觉特征簇的候选集合, 而不是依赖单点重要性分数。

给定视觉 token 集合 $V = \{v_i\}_{i=1}^N$, 首先对 token 进行归一化:

$$\hat{v}_i = \frac{v_i}{\|v_i\|_2}.$$

定义 token 间余弦距离:

$$d(i, j) = 1 - \hat{v}_i^\top \hat{v}_j.$$

候选集合 $\mathcal{P}$ 初始化为空。首先选择最近邻距离最大的 token:

$$p_1 = \arg \max_{v_i \in V} \min_{v_j \in V, j \neq i} d(i, j).$$

随后迭代选择距离当前候选集合最远的 token:

$$p_t = \arg \max_{v_i \in V \setminus \mathcal{P}} \min_{p_j \in \mathcal{P}} d(i, p_j), \quad t = 2, \dots, M.$$

最终得到覆盖型候选集合:

$$\mathcal{P} = \{p_1, \dots, p_M\}, \quad M = \eta K.$$

在候选集合内部, 本文进一步估计局部特征峰。对于 $p_i, p_j \in \mathcal{P}$, 计算候选间距离 d_{ij} , 并基于 k 近邻估计局部密度:

$$\rho_i = \exp \left(-\frac{1}{k} \sum_{p_j \in \mathcal{N}_k^{\mathcal{P}}(p_i)} d_{ij} \right).$$

进一步计算局部峰间距离：

$$\delta_i^{\text{local}} = \begin{cases} \min_{j \in \mathcal{N}_{k'}^{\mathcal{P}}(p_i), \rho_j > \rho_i} d_{ij}, & \exists j \in \mathcal{N}_{k'}^{\mathcal{P}}(p_i), \rho_j > \rho_i, \\ \max_{j \in \mathcal{N}_{k'}^{\mathcal{P}}(p_i)} d_{ij}, & \text{otherwise.} \end{cases}$$

最终定义候选 token 的局部特征峰分数：

$$q_i = \rho_i \delta_i^{\text{local}}.$$

根据目标保留数量 K ，选择得分最高的 token：

$$S = \text{TopK}_{p_i \in \mathcal{P}}(q_i).$$

该方法先通过 max-min coverage 构建覆盖不同视觉特征簇的候选池，再在候选池内部选择局部特征峰，避免了基于范数或注意力的粗筛可能集中于背景或少数显著区域的问题。

设原始视觉 token 数为 N ，候选 token 数为 $M = \eta K$ ，特征维度为 D 。Coverage-aware 候选选择需要计算一次全局距离矩阵，复杂度为 $O(N^2 D)$ 。在维护每个 token 到当前候选集合最近距离的情况下，迭代选取 M 个候选的复杂度为 $O(NM)$ 。候选集合内部的局部密度峰估计复杂度为 $O(M^2)$ ；若重新计算候选间距离，则为 $O(M^2 D)$ 。因此总体复杂度为

$$O(N^2 D + NM + M^2),$$

其中主项为全局距离矩阵计算。虽然该过程高于简单响应强度筛选，但其避免了高范数背景 token 偏置，并能显式保证候选集合对视觉特征簇的覆盖。